

POLITÉCNICO GRANCOLOMBIANO

Facultad de Ingeniería y Ciencias Básicas

DISEÑO DE ARQUITECTURA DE DATOS

para una Multinacional de Productos Alimenticios en Latinoamérica

Actividad Sumativa — Entrega Proyecto Colaborativo 1

Módulo: Arquitectura de Datos — Unidad 2

Bogotá D.C., Colombia — 2025

1. Introducción

En el contexto del auge de la economía digital y la transformación de los procesos organizacionales mediados por tecnología, la gestión estratégica de los datos se ha consolidado como un factor diferenciador clave para las empresas que operan en entornos complejos y distribuidos. La arquitectura de datos, entendida como el conjunto de modelos, políticas, reglas y estándares que gobiernan la recopilación, integración, almacenamiento, gestión y uso de los datos en una organización, constituye el cimiento sobre el cual se sostienen los procesos de inteligencia de negocios, la toma de decisiones basada en evidencia y la innovación impulsada por datos.

El presente informe aborda el diseño de una arquitectura de datos para una empresa multinacional dedicada a la producción y comercialización de productos alimenticios a lo largo de toda Latinoamérica. Esta organización gestiona un portafolio diverso que incluye galletas, snacks, embutidos, chocolates, cafés, helados y pastas, y opera sistemas de información heterogéneos: sistemas de producción en múltiples plantas, CRM, ERP, sistema contable diferenciado por país, plataformas de apoyo a la toma de decisiones y canales de captura de datos externos como redes sociales, encuestas de satisfacción y reportes sectoriales.

La complejidad de este ecosistema exige un diseño de arquitectura de datos que garantice la interoperabilidad entre sistemas, la calidad e integridad de los datos, la trazabilidad de los procesos de negocio y la capacidad de escalar hacia soluciones analíticas avanzadas. En este documento se identifican las fuentes de datos internas y externas, se establecen los elementos para asegurar la calidad de los datos y se proponen los principios arquitectónicos que deben orientar el diseño.

2. Objetivos

2.1 Objetivo General

Diseñar una arquitectura de datos unificada para una multinacional de productos alimenticios en Latinoamérica, que integre las fuentes de datos internas y externas, garantice la calidad de los datos y responda a los principios de buena arquitectura, con el fin de apoyar eficientemente los procesos de negocio y la toma de decisiones estratégicas.

2.2 Objetivos Específicos

1. Identificar y clasificar las fuentes de datos internas y externas de la organización, describiendo su naturaleza, formato y relevancia para los procesos organizacionales.
2. Definir los elementos necesarios para asegurar la calidad de los conjuntos de datos, incluyendo criterios de completitud, consistencia, exactitud, vigencia e integridad.
3. Establecer los principios de arquitectura de datos aplicables al caso de estudio, detallando cómo cada principio se materializa en el diseño propuesto.

3. Descripción del Problema

La organización objeto de estudio es una multinacional del sector alimenticio con presencia en múltiples países de América Latina. Su portafolio incluye galletas, snacks, embutidos, chocolates, cafés, helados y pastas. Sus procesos de negocio son soportados por un conjunto heterogéneo de sistemas de información:

- Sistema de información de producción en cada planta de fabricación (MES/SCADA).
- Sistema de Gestión de Relaciones con Clientes (CRM) a nivel corporativo.
- Sistema de Planificación de Recursos Empresariales (ERP) integrado.
- Sistemas contables independientes por país para cumplir normativas fiscales locales.
- Sistema de apoyo a la toma de decisiones (DSS/BI) en niveles: procesos, ciudades, países y regiones.

Adicionalmente, la organización captura datos externos: comentarios en la página web, interacciones en redes sociales, encuestas de satisfacción al cliente, encuestas a distribuidores e informes sectoriales de organismos de diferentes países.

El principal reto es la ausencia de una arquitectura de datos unificada. La dispersión de sistemas genera silos de datos, inconsistencias en reportes, dificultades para el análisis consolidado y limitaciones para escalar hacia soluciones de analítica avanzada e inteligencia artificial.

4. Identificación de Fuentes de Datos

El levantamiento de fuentes de datos es el primer paso en el diseño de una arquitectura. Para la multinacional alimenticia, las fuentes se clasifican en internas y externas.

4.1 Fuentes de Datos Internas

4.1.1 Sistema de Información de Producción (MES/SCADA)

Cada planta genera datos operacionales en tiempo real: variables de proceso, órdenes de producción, tiempos de ciclo, consumo de insumos, eficiencia de líneas y trazabilidad de lotes. Son la base para la analítica operativa y el control de calidad en la cadena productiva.

Atributo	Descripción
Tipo de dato	Estructurado y semi-estructurado (series de tiempo)
Volumen	Alto (generación continua por planta)
Frecuencia	Tiempo real / cada minuto
Formato	SQL, CSV, OPC-UA, JSON
Sistema origen	MES, SCADA, PLCs

4.1.2 Sistema CRM (Customer Relationship Management)

Contiene información sobre clientes, canales de distribución, historial de pedidos, interacciones comerciales y segmentación de mercado. Es crítica para los análisis de comportamiento del consumidor y predicción de demanda.

Atributo	Descripción
Tipo de dato	Estructurado
Volumen	Medio-Alto
Frecuencia	Diaria / en tiempo real
Formato	SQL, API REST, JSON
Sistema origen	Salesforce, SAP CRM, HubSpot u equivalente

4.1.3 Sistema ERP (Enterprise Resource Planning)

El ERP integra finanzas, logística, compras, inventario, recursos humanos y planificación de producción. Es el núcleo transaccional de la organización y la fuente principal para análisis financieros y de cadena de suministro.

Atributo	Descripción
Tipo de dato	Estructurado
Volumen	Alto
Frecuencia	Batch diario / transaccional en tiempo real
Formato	SQL, IDOC, XML, CSV
Sistema origen	SAP ERP, Oracle ERP u equivalente

4.1.4 Sistemas Contables por País

Cada país mantiene un sistema contable independiente para cumplir con normativas fiscales locales (NIIF, normativas tributarias de Colombia, México, Brasil, Argentina, Chile, entre otros). Son críticos para la consolidación financiera regional y el cumplimiento regulatorio.

Atributo	Descripción
Tipo de dato	Estructurado
Volumen	Medio
Frecuencia	Mensual / en cierre contable
Formato	SQL, XML, CSV, XBRL
Países	Colombia, México, Brasil, Argentina, Chile, Perú y otros

4.1.5 Sistema DSS/BI (Apoyo a la Toma de Decisiones)

Agrega y procesa datos de los demás sistemas internos para generar KPIs, tableros de control y reportes ejecutivos en múltiples niveles: procesos, ciudades, países y regiones.

Atributo	Descripción
Tipo de dato	Estructurado (datos procesados/agregados)
Volumen	Medio
Frecuencia	Diaria / semanal / mensual
Formato	OLAP Cubes, Parquet, CSV, JSON
Sistema origen	Power BI, Tableau, MicroStrategy u equivalente

4.2 Fuentes de Datos Externas

4.2.1 Página Web Corporativa (Comentarios y Formularios)

Los usuarios dejan comentarios, valoraciones y consultas en la página web oficial. Genera datos semi-estructurados y no estructurados valiosos para el análisis de sentimiento y la identificación de oportunidades de mejora en productos y servicios.

Atributo	Descripción
Tipo de dato	Semi-estructurado y no estructurado
Volumen	Bajo-Medio
Frecuencia	Continua (eventos)
Formato	JSON, XML, texto plano
Herramienta	Web scraping, CMS, formularios web

4.2.2 Redes Sociales

Instagram, Facebook, Twitter/X y TikTok generan conversaciones, menciones de marca y reseñas de productos. Fundamentales para el monitoreo de reputación y el análisis de sentimiento del consumidor en tiempo casi real.

Atributo	Descripción
Tipo de dato	No estructurado (texto, imagen, video)
Volumen	Alto
Frecuencia	Tiempo real / streaming
Formato	JSON (API), texto, multimedia
Herramienta	APIs oficiales (Meta, X), herramientas de social listening

4.2.3 Encuestas de Satisfacción al Cliente

Encuestas periódicas a consumidores finales para medir satisfacción con productos y experiencia de compra. Datos semi-estructurados (escala Likert) y no estructurados (preguntas abiertas).

Atributo	Descripción
Tipo de dato	Estructurado y semi-estructurado
Volumen	Bajo-Medio
Frecuencia	Trimestral / puntual
Formato	CSV, JSON, Excel
Herramienta	SurveyMonkey, Google Forms, Qualtrics

4.2.4 Encuestas a Distribuidores

Recopila información de los canales de distribución sobre disponibilidad de productos, eficiencia logística y condiciones de almacenamiento. Esencial para optimizar la cadena de suministro.

Atributo	Descripción
Tipo de dato	Estructurado y semi-estructurado
Volumen	Bajo
Frecuencia	Mensual / trimestral
Formato	CSV, JSON, Excel

Herramienta	Plataformas de encuestas, correo electrónico
-------------	--

4.2.5 Informes Sectoriales y Datos de Mercado

Organismos internacionales, institutos estadísticos y consultoras publican informes sobre el sector alimenticio, tendencias de consumo y regulaciones vigentes. Enriquecen los modelos de predicción de demanda y los análisis de expansión de mercado.

Atributo	Descripción
Tipo de dato	Estructurado y no estructurado (PDF, informes)
Volumen	Bajo-Medio
Frecuencia	Mensual / anual
Formato	PDF, Excel, JSON, CSV, XML
Fuentes ejemplo	DANE, INEGI, IBGE, Nielsen, Euromonitor

4.3 Tabla Consolidada de Fuentes de Datos

La Tabla 1 presenta el resumen integrado de todas las fuentes identificadas, clasificadas por origen, tipo de dato y nivel de criticidad para la organización.

Fuente	Origen	Tipo de Dato	Frecuencia	Criticidad
Sistema de Producción (MES/SCADA)	Interna	Estructurado / Series tiempo	Tiempo real	Crítica
CRM	Interna	Estructurado	Diaria	Alta
ERP	Interna	Estructurado	Diaria / Tiempo real	Crítica
Sistemas Contables por País	Interna	Estructurado	Mensual	Crítica
DSS / BI	Interna	Estructurado (procesado)	Diaria / Mensual	Alta
Página Web (Comentarios)	Externa	Semi-estr./No estructurado	Continua	Media
Redes Sociales	Externa	No estructurado	Tiempo real	Alta
Encuestas de Satisfacción	Externa	Estructurado/Semi-estr.	Trimestral	Media
Encuestas a Distribuidores	Externa	Estructurado/Semi-estr.	Mensual	Media
Informes Sectoriales	Externa	Estr./No estructurado	Mensual/Anual	Media

5. Elementos para Asegurar la Calidad de los Conjuntos de Datos

La calidad de los datos es un requisito fundamental para que la arquitectura cumpla su propósito. Datos de baja calidad comprometen la confiabilidad de los análisis y la validez de las decisiones. Se definen siete dimensiones de calidad contextualizadas al caso de la multinacional.

5.1 Completitud

Grado en que los datos contienen todos los valores necesarios para satisfacer los requerimientos del negocio. En la multinacional es especialmente crítica en el ERP (registros de inventario sin cantidades) y en los sistemas contables (transacciones sin código de costo).

Medida de aplicación: Umbrales de completitud por tabla y campo crítico. Para el módulo de inventario del ERP se exige 100% de completitud en: código de producto, cantidad, unidad de medida y fecha de registro. Se implementarán validaciones automáticas en el pipeline de ingesta con dbt o Great Expectations.

5.2 Exactitud

Correspondencia entre los valores registrados y la realidad que representan. Datos inexactos generan errores en reportes de producción e inconsistencias en estados financieros.

Medida de aplicación: Controles de validación cruzada entre MES y ERP para verificar que las cantidades producidas concuerden con las registradas en inventario. Para encuestas, se definirán rangos de validez por variable (calificaciones 1-5 no pueden tomar valores fuera del rango).

5.3 Consistencia

Los datos no presentan contradicciones entre sí, ya sea dentro del mismo sistema o entre sistemas distintos. La consistencia entre cifras contables locales y la consolidación regional es un reto crítico para la multinacional.

Medida de aplicación: Reglas de consistencia inter-sistema en la capa de integración. El código de producto en el ERP debe coincidir con el código en MES y CRM. Se implementará un sistema MDM (Master Data Management) para garantizar la coherencia de entidades clave: productos, clientes, proveedores y ubicaciones.

5.4 Vigencia (Actualidad)

Los datos deben estar actualizados y reflejar el estado actual de las entidades que representan. Datos desactualizados generan análisis basados en información obsoleta.

Medida de aplicación: Políticas de actualización por tipo de fuente. Para redes sociales la vigencia es de horas; para informes sectoriales puede ser anual. Se implementarán

alertas automáticas cuando la latencia supere los umbrales definidos por dominio de datos.

5.5 Unicidad (No Duplicidad)

Garantiza que cada entidad esté representada una sola vez en el sistema. Los registros duplicados distorsionan los análisis de ventas, inventario y satisfacción del cliente.

Medida de aplicación: Procesos de deduplicación en la capa de staging del Data Lake usando algoritmos de coincidencia difusa (fuzzy matching) para detectar duplicados en nombres de clientes y productos provenientes de sistemas legados.

5.6 Integridad Referencial

Asegura que las relaciones entre entidades sean válidas: no pueden existir órdenes de producción asociadas a productos inexistentes ni facturas vinculadas a clientes no registrados en el CRM.

Medida de aplicación: Restricciones de integridad referencial en los modelos del Data Warehouse. En el pipeline de ingesta se validará la existencia de claves foráneas antes de cargar registros en la capa definitiva.

5.7 Conformidad (Estandarización de Formatos)

Los datos deben seguir formatos y estándares definidos. En una multinacional con operaciones en múltiples países, la estandarización de fechas, monedas, unidades de medida y códigos geográficos es fundamental.

Medida de aplicación: Catálogo de estándares corporativos: formato de fecha ISO 8601 (YYYY-MM-DD), moneda ISO 4217 (COP, MXN, BRL, etc.), unidades (kg, litros, unidades) y códigos geográficos ISO 3166-1 alpha-2. Transformaciones de normalización en la capa ETL/ELT.

5.8 Resumen de Dimensiones de Calidad

Dimensión	Descripción	Herramienta / Mecanismo	Fuente Aplicable
Compleitud	Campos obligatorios con valor	dbt tests, Great Expectations	ERP, CRM, MES
Exactitud	Valores reflejan la realidad	Validación cruzada inter-sistema	ERP, MES, Encuestas
Consistencia	Sin contradicciones entre sistemas	MDM, reglas de integración	Todos los sistemas
Vigencia	Datos actualizados según frecuencia	Alertas de latencia en pipelines	Redes sociales, Contabilidad
Unicidad	Sin registros duplicados	Fuzzy matching, deduplicación	CRM, ERP, fuentes externas
Integridad Referencial	Relaciones válidas entre entidades	Restricciones en Data Warehouse	ERP, CRM, MES
Conformidad	Datos en formatos estándar	Transformaciones ETL/ELT	Contabilidad, Producción

6. Principios para una Buena Arquitectura de Datos

Los principios de arquitectura de datos son lineamientos fundamentales que guían las decisiones de diseño, implementación y evolución del sistema. Se adoptan ocho principios con aplicación concreta al caso de la multinacional alimenticia.

Principio 1: Orientación al Negocio

La arquitectura debe estar diseñada para responder a las necesidades del negocio y generar valor tangible, no para satisfacer únicamente criterios técnicos.

Aplicación: El diseño prioriza los dominios críticos: producción, ventas, finanzas y experiencia del cliente. El Data Warehouse se estructura alrededor de procesos clave: planificación de producción, análisis de ventas por producto y región, consolidación financiera y monitoreo de satisfacción. Cada componente tiene un caso de uso de negocio específico que lo justifica.

Principio 2: Unicidad de Fuentes de Verdad (Single Source of Truth)

Para cada entidad o dominio de datos debe existir una única fuente autorizada de información reconocida por todos los sistemas.

Aplicación: Se implementará un sistema MDM que defina la fuente de verdad para: Producto (ERP), Cliente (CRM), Proveedor (ERP), Planta de producción (MES) y País/Región (tabla maestra corporativa). Cualquier sistema que necesite referenciar estas entidades las consulta desde el MDM, sin mantener copias locales.

Principio 3: Escalabilidad

La arquitectura debe crecer en volumen, variedad y velocidad de datos sin requerir rediseños fundamentales, anticipando el crecimiento del negocio.

Aplicación: Se adopta un Data Lake sobre almacenamiento en la nube (AWS S3, Azure Data Lake Storage Gen2 o Google Cloud Storage) con escalamiento elástico. Apache Spark en Databricks escala horizontalmente según demanda. La incorporación de nuevas fuentes (por ejemplo, datos IoT de plantas) solo requiere agregar nuevos pipelines de ingesta, sin modificar la arquitectura base.

Principio 4: Seguridad y Privacidad por Diseño

La protección de los datos debe ser un atributo del diseño, no una capa añadida a posteriori. Incluye control de acceso, cifrado, auditoría y cumplimiento normativo.

Aplicación: Se implementará RBAC (Role-Based Access Control) para que cada usuario acceda solo a los datos necesarios. Los datos sensibles serán cifrados en reposo y en tránsito. Se cumplirá con: Ley 1581 de Colombia, LGPD de Brasil, LFPDPPP de México y normativas equivalentes en cada país de operación.

Principio 5: Interoperabilidad

Los componentes deben comunicarse e intercambiar información eficientemente, independientemente de las tecnologías, formatos o protocolos utilizados.

Aplicación: Se adoptarán estándares abiertos: APIs REST para la comunicación entre sistemas, formatos Parquet y Avro para el Data Lake, y Apache Kafka como bus de mensajes para la integración en tiempo real entre el sistema de producción, el ERP y el CRM. La capa de integración será tecnológicamente agnóstica.

Principio 6: Trazabilidad y Linaje de Datos

Debe ser posible rastrear el origen, las transformaciones y el destino de cada dato a lo largo de todo el pipeline, desde su captura hasta su uso en reportes.

Aplicación: Se implementará un sistema de linaje (Apache Atlas o OpenLineage) que registre automáticamente cada transformación en el pipeline ETL/ELT. Ante una inconsistencia en un reporte financiero consolidado, será posible identificar exactamente en qué paso se introdujo el error. El linaje es especialmente crítico para los sistemas contables, donde la auditoría regulatoria exige demostrar el origen e integridad de cada cifra.

Principio 7: Reutilización y Modularidad (Arquitectura Medallion)

Los componentes deben diseñarse para ser reutilizables en múltiples casos de uso, evitando la duplicación de esfuerzos y garantizando la consistencia de resultados.

Aplicación: Se adoptará la arquitectura Medallion con tres capas: Bronze (datos crudos de todas las fuentes), Silver (datos limpios y estandarizados listos para múltiples análisis) y Gold (modelos orientados a casos de uso específicos: reportes financieros, análisis de demanda, monitoreo de calidad). Este diseño evita reprocesar datos desde cero para cada caso de uso.

Principio 8: Gobierno y Responsabilidad

La arquitectura debe estar respaldada por un marco de gobierno que defina responsabilidades sobre los datos, procesos de toma de decisiones y mecanismos de cumplimiento de políticas.

Aplicación: Se creará un Comité de Gobierno de Datos integrado por representantes de TI, Finanzas, Producción, Comercial y Jurídica. Responsable de: aprobar el catálogo de datos maestros, establecer políticas de calidad y seguridad, resolver conflictos de propiedad de datos entre áreas y definir las prioridades del roadmap de la arquitectura.

6.1 Resumen de Principios

Principio	Elemento Clave	Herramienta / Mecanismo
1. Orientación al Negocio	Valor para el negocio	Casos de uso por área de negocio
2. Unicidad de Fuentes de Verdad	MDM corporativo	Apache Atlas, AWS Glue
3. Escalabilidad	Crecimiento elástico	Data Lake en nube, Apache Spark
4. Seguridad y Privacidad	RBAC, cifrado, cumplimiento	IAM, TLS, logs de auditoría
5. Interoperabilidad	Estándares abiertos	API REST, Kafka, Parquet
6. Trazabilidad	Linaje de datos	Apache Atlas, OpenLineage
7. Reutilización y Modularidad	Arquitectura Medallion	Capas Bronze / Silver / Gold

8. Gobierno y Responsabilidad	Comité de Gobierno de Datos	Políticas, catálogo, stewards
-------------------------------	-----------------------------	-------------------------------

7. Conclusiones

4. La identificación exhaustiva de fuentes de datos, tanto internas como externas, es el punto de partida ineludible para cualquier diseño de arquitectura. La multinacional cuenta con diez fuentes heterogéneas que generan datos estructurados, semi-estructurados y no estructurados a diferentes frecuencias. Su gestión unificada requiere una capa de integración robusta y tecnológicamente agnóstica.
5. La calidad de los datos requiere un marco sistemático que aborde las siete dimensiones identificadas y esté respaldado por procesos de gobierno formalizados. La implementación de un Data Catalog y el monitoreo continuo de calidad son condiciones necesarias para la confiabilidad de los análisis.
6. Los ocho principios de arquitectura de datos forman un sistema coherente: la orientación al negocio define las prioridades, la escalabilidad y la modularidad garantizan la sostenibilidad técnica, y el gobierno y la seguridad aseguran el cumplimiento normativo. La arquitectura Medallion sobre un Data Lake en la nube es el patrón que mejor materializa estos principios.
7. El diseño propuesto constituye la base para que la organización evolucione hacia capacidades analíticas avanzadas: predicción de demanda, optimización de la cadena de suministro, análisis de sentimiento del consumidor y sistemas de recomendación, todos posibles gracias a una arquitectura de datos bien fundamentada.

8. Referencias Bibliográficas

- Brackett, M. H. (1994). Data Sharing Using a Common Data Architecture. John Wiley & Sons.
- Dama International. (2017). DAMA-DMBOK: Data Management Body of Knowledge (2nd ed.). Technics Publications.
- Inmon, W. H. (2002). Building the Data Warehouse (4th ed.). John Wiley & Sons.
- Kimball, R., & Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling (3rd ed.). John Wiley & Sons.
- Kleppmann, M. (2017). Designing Data-Intensive Applications. O'Reilly Media.
- Ladley, J. (2012). Data Governance: How to Design, Deploy and Sustain an Effective Data Governance Program. Morgan Kaufmann.
- Redman, T. C. (2001). Data Quality: The Field Guide. Digital Press.
- Wang, R. Y., & Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4), 5-33.
<https://doi.org/10.1080/07421222.1996.11518099>
- Zachman, J. A. (1987). A framework for information systems architecture. *IBM Systems Journal*, 26(3), 276-292. <https://doi.org/10.1147/sj.263.0276>