




Lectura fundamental 1

Procesamiento de datos orientados a diferentes modelos arquitectónicos

Módulo: Arquitectura de Datos

Unidad 4



Contenido

- 1 Introducción
- 2 Modelamiento de datos
- 3 Proceso de extracción, transformación y carga de datos (ETL)
- 4 Preparación de datos para procesos de análisis y ciencia de datos
- 5 Conclusiones

1. Introducción

En esta lectura se abordará un tema crítico a la hora de proponer estrategias de arquitectura de datos que es el modelamiento de los datos, aspecto al que muchas veces no se le da la importancia que requiere y sí puede ser un factor que determine el éxito de los sistemas que permiten recolectar, almacenar y analizar datos de las organizaciones.

Conocer formas de hacer el modelamiento de datos en diferentes niveles son conocimientos claves para aprovechar tanto la información que va a almacenar como las ventajas que pueden ofrecer las herramientas en diferentes componentes que pueda tener una arquitectura de datos. Además, los escenarios más frecuentes integran modelos de datos diversos de acuerdo con la fase del ciclo de vida de los datos y también teniendo en cuenta las posibles fuentes de datos que tenga la organización.

Tener un panorama claro de las necesidades de almacenamiento y la procedencia de los datos es lo que permitirá tomar decisiones acertadas sobre los modelos de datos, las estrategias de ETL (extracción, transformación y carga de datos) y también la preparación de datos para procesos de análisis y ciencia de datos. Si estos elementos se evalúan e implementan de forma adecuada y acorde a las necesidades y recursos de la organización, lo más seguro es que la explotación final de los datos genere información nueva sobre el negocio y conocimiento interesante que pueda aportar a las decisiones de productos, servicios, oferta, inversiones, finanzas y procesos en general.

2. Modelamiento de datos

Con frecuencia, al modelado de datos no se le presta la atención debida y se pasa a la creación de sistemas de datos, sin un plan para organizarlos de una manera que los haga útiles para el negocio, lo cual es un error. Las arquitecturas de datos bien construidas tienen como objetivo responder a las metas y lógica organizacional que depende de esos datos.

Se han utilizado técnicas para modelar datos desde los primeros días de los sistemas de gestión de bases de datos. Las técnicas de modelado de almacenes de datos han existido desde, al menos, principios de los años 1990, tal vez incluso más tiempo. Como las tendencias muchas veces vuelven a repetirse en la tecnología, el modelado de datos pasó de moda entre principios y mediados de la década de 2010. El creciente uso de los lagos de datos (*data lakes*), NoSQL y los sistemas de *Big Data* permitió evitar el uso del modelado de datos tradicional, lo cual generó ganancias en cuanto al rendimiento en todo el manejo de datos. En otros casos, la falta de un modelado de datos

riguroso resultó en repositorios de datos poco útiles con grandes cantidades de datos redundantes, inconsistentes e incorrectos (Reis y Housley, 2022). En tiempos recientes la tendencia está volviendo al modelamiento de datos. Este interés también crece debido al énfasis que se hace en la gestión de datos con elementos de gobernanza y la calidad de datos, elementos que permiten responder a una lógica empresarial coherente. El aumento exponencial de la importancia de los datos en las organizaciones está llevando a un reconocimiento cada vez mayor de que el modelado es fundamental para ofrecer valor en los niveles más altos de la pirámide de la jerarquía de necesidades de la ciencia de datos, como se muestra en la Figura 1. Esta jerarquía define que estos niveles tienen el siguiente orden (Torres, 2021):

1. Recolección de datos: este nivel incluye lo siguiente:
 - Instrumentación
 - *Logging* (creación de cuentas de los usuarios)
 - Sensores
 - Datos externos
 - Contenido generado por el usuario

2. Movimiento y almacenamiento: este nivel incluye lo siguiente:
 - Datos confiables
 - Flujo
 - Infraestructura
 - Pipelines
 - ETL (*Extract, Transform, Load*)
 - Datos estructurados (es decir, que ya están organizados o clasificados por alguna estructura estándar)
 - Datos no estructurados (quiere decir que los datos están sueltos por ahí)

3. Exploración y transformación: este nivel incluye lo siguiente:

- Limpieza
- Detección de anomalías
- Preparación

4. Agregaciones y etiquetado: este nivel incluye lo siguiente:

- Estadísticas
- Métricas (son como las medidas de una actividad en concreto)
- Segmentación
- Agregaciones
- Características
- Entrenamiento de datos

5. Aprendizaje y optimización. Este nivel incluye lo siguiente:

- Pruebas A/B
- Experimentación
- Algoritmos simples ML
- Inteligencia artificial
- *Deep Learning*




Figura 1. Jerarquía de necesidades de la ciencia de datos

Fuente: elaboración propia

Por otro lado, creemos que se requieren nuevos paradigmas para abordar verdaderamente las necesidades de la transmisión de datos y el aprendizaje automático. En esta sección, analizamos las técnicas actuales de modelado de datos y reflexionamos brevemente sobre el futuro del modelado de datos.

2.1. ¿Qué es un modelo de datos?

Un modelo de datos adecuado tiene como meta dar la pauta de organización, estructura y estándar para los datos que están involucrados en procesos, definiciones, flujos de trabajo y lógica de negocio. Cuando se implementa un modelo de datos adecuado se permite registrar cómo la comunicación y el trabajo fluyen naturalmente en una organización. Al final, se busca que el modelo de datos refleje la forma en que los datos representan elementos del mundo real y conceptos presentes en los procesos de negocio (Reis y Housley, 2022).

Las buenas prácticas de arquitectura de datos reconocen que el modelado de datos es un punto clave sobre el cual empezar a construir un entendimiento del negocio para que luego se puedan aprovechar los datos como un activo, sin embargo, es frecuente que se ignore esto en la práctica. Cuando la organización desarrolla un modelo de datos a conciencia, está garantizando que la lógica y las reglas del negocio luego se puedan traducir en la capa de datos de los sistemas que se construyen alrededor. Hay que resaltar que, al buscar un buen modelo de datos, este debe tener una relación directa con las decisiones de negocio que efectivamente van a impactar los resultados. Por ejemplo, el término **cliente** puede tener diferentes concepciones para distintos departamentos de una organización. Es necesario preguntar: ¿es cliente alguien que le ha comprado en el último mes o trimestre?, ¿sigue siendo un cliente preferencial si no ha comprado en los últimos seis meses o un año? Generar este tipo de debates con las áreas de negocio, va a permitir expresar y modelar los datos de clientes que pueden tener un impacto significativo en los reportes posteriores sobre comportamiento del cliente o en la creación de modelos predictivos de abandono de clientes donde el tiempo desde la última compra es una variable crucial (Reis y Housley, 2022).

2.2. Modelos de datos conceptuales, lógicos y físicos

El proceso de modelado de datos incluye el aterrizar los conceptos más abstractos a una implementación concreta, pasando por tres modelos de datos: conceptual, lógico y físico (Reis y Housley, 2022).

Conceptual

Este modelo contiene las reglas y lógica del negocio, describe datos del sistema, como esquemas, tablas y campos (nombres) y tipos de datos. Es usual que al crear el modelo conceptual se visualice como un diagrama entidad-relación (ER), que es una herramienta estándar para visualizar las relaciones entre diferentes entidades en los datos. Por ejemplo, se pueden identificar como entidades a los clientes, productos, servicios y pedidos, y en el diagrama ER se puede identificar las relaciones entre el ID del cliente, el nombre del cliente, la dirección del cliente, los pedidos de los clientes, los productos y servicios de los pedidos.

Lógico

En este modelo se busca describir cómo se implementará el modelo conceptual en la práctica, agregando detalles adicionales, como los tipos de atributos y los datos posibles para los atributos, como los tipos de identificación de clientes, tamaño de los nombres de clientes y direcciones especiales, también se identifican la clave primaria y foránea de cada tabla.

Físico

El modelo físico permite definir cómo se implementará el modelo lógico en el motor de base de datos, por lo cual se agregan las bases de datos necesarias, esquemas y tablas específicas del modelo lógico, y características de configuración.

2.3. Normalización

Esta estrategia de modelado de bases de datos permite tener un control estructurado sobre las relaciones de tablas, filas y columnas dentro de una base de datos, a través de la eliminación de la redundancia de datos y garantizar la integridad referencial. Este concepto fue creado a principios de la década de 1970 por el pionero de las bases de datos relacionales Edgar Codd (Kolade, 2023). Los cuatro objetivos principales de la normalización son:

1. Eliminar las relaciones de dependencias de inserción, actualización y eliminación no deseadas.
2. Reducir la necesidad de reestructurar las tablas (relaciones) cuando se introducen nuevos tipos de datos, lo que permite que se aumente la vida útil de las aplicaciones de *software*.
3. Hacer que el modelo relacional sea más informativo para los usuarios.
4. Hacer que la recopilación de datos de las relaciones sea transparente para las estadísticas de consulta, que pueden cambiar con el tiempo.

Junto con el concepto de normalización Codd presentó la idea de las formas normales que son secuenciales y cada forma asegura que se cumplan con las condiciones de las formas anteriores. Aquí describimos las tres primeras formas normales de Codd (para ampliar este concepto ver (Kolade, 2023):

Desnormalizado

Sin normalización. Se permiten datos anidados y redundantes.

Primera forma normal (1NF)

Cada columna es única y tiene un valor único. La tabla tiene una clave primaria única.

Segunda forma normal (2NF).

Se cumplen los requisitos de 1NF y se eliminan las dependencias parciales.

Tercera forma normal (3NF).

Se cumple con la segunda forma normal (2NF) y también asegura que cada tabla solo contenga campos relevantes relacionados con su clave principal y no tenga dependencias transitivas.

Es importante recordar que una clave primaria única es un campo único o un conjunto de campos múltiples que identifica de forma única un registro de una tabla. Cada valor clave ocurre como máximo una vez; de lo contrario, se asignaría un valor a varias filas de la tabla. Se puede dar el caso de una dependencia parcial, que ocurre cuando un subconjunto de campos en una clave compuesta se puede usar para determinar una columna que no es clave de la tabla. Una dependencia transitiva ocurre cuando un campo no clave depende de otro campo no clave (Kolade, 2023). Veamos las etapas de normalización, desde desnormalizada hasta 3NF, utilizando un ejemplo de la construcción una aplicación de administración de un restaurante. Esa aplicación necesita almacenar datos sobre los empleados de la compañía y comienza creando la siguiente tabla de empleados (Kolade, 2023).

Tabla 1. Ejemplo restaurante en primera forma normal (1NF)

EMPLEADO ID	NOMBRE	CÓDIGO TRABAJO	TRABAJO	CÓDIGO ESTADO	ESTADO
E001	Alicia	C01	Chef	26	Florida
E001	Alicia	C02	Mesero	26	Florida
E002	Roberto	C02	Mesero	56	California
E002	Roberto	C03	Bartender	56	California
E003	Alicia	C01	Chef	56	California

Fuente: modificado de Kolade (2023)

En la Tabla 1, todos los datos de cada atributo son atómicos (un solo valor) y hay una clave primaria compuesta que incluye los atributos Empleado_id y código_trabajo, así que la tabla está en la primera forma normal (1NF).

Pero incluso si solamente se conoce el Empleado_id de alguien, entonces se puede determinar su Nombre, Estado, y Código_estado (porque deberían ser la misma persona). Esto significa que Nombre, Estado, y Código_estado son dependientes funcionalmente de Empleado_id (una parte de la clave primaria compuesta). Así que la tabla no está en 2NF y se necesita una tabla distinta.

El modelo en segunda forma normal (2FN) incluiría la Tabla 2, la Tabla 3 y la Tabla 4, donde el atributo Estado depende funcionalmente de código_estado en la Tabla 2. Si se conoce el código_estado, entonces se puede encontrar el valor del Estado.

Tabla 2. Empleados – Roles – modelo en Segunda forma normal (2NF)

EMPLEADO ID	CÓDIGO TRABAJO
E001	J01
E001	J02
E002	J02
E002	J03
E003	J01

Fuente: modificado de Kolade (2023)

Tabla 3. Empleados – modelo en Segunda forma normal (2NF)

EMPLEADO ID	NOMBRE	CÓDIGO ESTADO	ESTADO
E001	Alicia	26	Florida
E002	Roberto	56	California
E003	Alicia	56	California

Fuente: modificado de Kolade (2023)

Tabla 4. Trabajos – modelo en Segunda forma normal (2NF)

JOB_CODE	JOB
J01	Chef
J02	Mesero
J03	Bartender

Fuente: modificado de Kolade (2023)

Aún se puede normalizar más, entonces se puede generar una tabla distinta para llevar el modelo a la tercera forma normal (3NF).

El modelo en segunda forma normal (2FN) incluiría la Tabla 5, la Tabla 6, la Tabla 7 y la Tabla 8.

Tabla 5. Empleados – Roles – modelo en tercera forma normal (3NF)

EMPLEADO_ID	CÓDIGO_TRABAJO
E001	J01
E001	J02
E002	J02
E002	J03
E003	J01

Fuente: modificado de Kolade (2023)

Tabla 6. Empleados – modelo en tercera forma normal (3NF)

EMPLEADO ID	NOMBRE	CÓDIGO ESTADO
E001	Alicia	26
E002	Roberto	56
E003	Alicia	56

Fuente: modificado de Kolade (2023)

Tabla 7. Trabajos – modelo en tercera forma normal (3NF)

CÓDIGO_TRABAJO	NOMBRE_TRABAJO
J01	Chef
J02	Mesero
J03	Bartender

Fuente: modificado de Kolade (2023)

Tabla 8. Estados – modelo en tercera forma normal (3NF)

CÓDIGO ESTADO	ESTADO
26	Florida
56	California

Fuente: modificado de Kolade (2023)

2.3.1. Modelos de datos analíticos por lotes

En el modelado de datos para lagos o almacenes de datos se debe asumir que los datos sin procesar pueden tomar formas estructuradas, semiestructuradas y no estructuradas, pero el resultado es un modelo de datos estructurado de filas y columnas. En estos entornos se pueden utilizar diferentes enfoques para el modelado de datos que siguen a los principales autores del tema Kimball y Inmon, así como el enfoque de *data vault* (Reis y Housley, 2022). En la práctica, al plantearse esquemas de arquitectura de datos estos métodos se pueden combinar. Por ejemplo, se puede empezar por una bodega de datos y luego agregan un esquema estrella de Kimball que lo complementa. También se pueden tener esquemas de conjuntos de datos desnormalizados bajo el mismo entorno.

Modelo Inmon

El padre del concepto de bodega de datos, Bill Inmon, creó su enfoque para el modelado de datos en 1990. Antes de la bodega de datos, el análisis de datos se realizaba directamente en el propio sistema fuente, con la consecuencia obvia de sobrecargar el sistema de gestión de las bases de datos transaccionales de producción con procesos de consulta de larga duración. Cuando se crea la bodega de datos se busca tener separados los sistemas fuente de datos de los sistemas analíticos (Reis y Housley, 2022; Inmon, 2005).

Para Inmon el concepto de bodega de datos es una colección de datos orientada a un tema, integrada, no volátil y variable en el tiempo, que respalda las decisiones de la gerencia. En este esquema se almacenan datos corporativos con diferentes niveles de granularidad (por ejemplo, año, mes, semana día). Estos datos se pueden utilizar para propósitos diferentes, incluyendo los que aún sean desconocidos hoy y que puedan explotarse en el futuro.

Para este autor, las cuatro partes críticas de una bodega de datos son las siguientes:

- **Orientado al tema:** la bodega de datos tiene un enfoque claro en un área específica, como ventas o marketing.
- **No volátil:** los datos permanecen, no cambian después de que se almacenan en la bodega de datos.
- **Integrado:** los datos de fuentes diferentes se consolidan en una sola y se normalizan sus formatos para que se puedan procesar como un único conjunto de datos.
- **Variante de tiempo:** se busca que se puedan ejecutar consultas seleccionando distintos rangos de tiempo.

Si se aterrizan estas características a un ejemplo, si se enfoca la bodega de datos en "ventas", entonces el modelo lógico contiene todos los detalles relacionados con las ventas: claves comerciales, relaciones, atributos, etc. Luego los datos se integran en un modelo de datos consolidado y altamente normalizado. Finalmente, los datos se almacenan sin cambios en un formato no volátil y variable en el tiempo, lo que significa que se pueden consultar los datos originales durante el tiempo que lo permita el historial de almacenamiento para respaldar las decisiones de la gerencia.

Otra característica destacada de la bodega de datos de Inmon es que está integrada. Los datos se introducen desde fuentes múltiples y en formatos diferentes. A medida que se guardan los datos en la bodega, se transforman, reformatean, reordenan, resumen, etc. El resultado al integrar los datos en la bodega de datos es que se obtiene una única imagen organizacional que puede ser analizada (Inmon, 2005).

Al final, la bodega de datos de Inmon es un conjunto de bases de datos de fuentes clave y sistemas de información utilizados en una organización con un formato altamente normalizado (3NF) que a menudo se parece mucho a la estructura de normalización del propio sistema de origen. La bodega va creciendo a medida que se incorporan los datos de forma incremental, comenzando con las áreas comerciales de mayor prioridad. El estricto requisito de normalización garantiza la menor duplicación de datos posible, lo que conduce a menos errores analíticos posteriores porque los datos no divergirán ni sufrirán redundancias. Los datos son presentados a través de informes y análisis posteriores a través de lagos de datos específicos por departamento o negocio específico (Reis y Housley, 2022; Inmon, 2005).

Veamos cómo se utiliza un almacén de datos de Inmon para el comercio electrónico (Figura 2). Los sistemas de origen empresarial son pedidos, inventario y marketing. Los datos de estos sistemas de origen se envían mediante ETL al almacén de datos y se almacenan en 3NF. Idealmente, el almacén de datos abarca de manera integral la información de la empresa. Para servir datos para solicitudes de información específicas de un departamento, los procesos ETL toman datos del almacén de datos, los transforman y los colocan en mercados de datos posteriores para verlos en informes.




Figura 2. Ejemplo bodega de datos con modelo Inmon

Fuente: elaboración propia

Modelo Kimball

Este modelo fue propuesto por el autor de múltiples libros de bodegas de datos llamado Ralph Kimball a principios de la década de 1990. Se enfoca menos en la normalización y, en algunos casos, acepta la desnormalización. Mientras que en el enfoque Inmon se integran los datos de toda la organización en una bodega de datos con lo que se puede ofrecer análisis de departamentos específicos a través de *data marts*; en el modelo de Kimball que es ascendente, se usa para modelar y proporcionar análisis departamentales o comerciales en su propia bodega de datos (Kimball y Ross, 2011). Esta estrategia permite iteraciones y modelados más rápidos que las que se hacen con modelo Inmon, con la posibilidad de una integración, redundancia y replicación de datos de forma más flexible (Reis y Housley, 2022). En este modelo, los datos son modelados con dos tipos de tablas: hechos y dimensiones. Puede pensar en una tabla de hechos como una tabla de números y en una tabla de dimensiones como datos cualitativos que se refieren a un hecho. Las tablas de dimensiones rodean una tabla de hechos única en una relación llamada esquema en estrella como se aprecia en la Figura 3 (Kimball & Ross, 2011).




Figura 3 Ejemplo bodega de datos con modelo Kimball

Fuente: modificado de Kimball y Ross (2011)

- a. Tablas de hechos. esta tabla contiene los datos fácticos o relacionados con los hechos, y los guarda con tipos cuantitativos. Estos datos son inmutables porque los hechos están asociados con eventos, por lo cual, las tablas de hechos no cambian y son de solo-agregar (en inglés, *append-only*). Estas tablas tienden a ser estrechas y largas, es decir, tienen pocas columnas, y muchas filas que representan eventos. Se busca tener el mayor nivel de detalle posible (Kimball y Ross, 2011). Para que se puedan ejecutar las consultas sobre un esquema en estrella se requiere empezar con una tabla de hechos. Es una tabla central y es la guía para

ejecutar las consultas por esta razón se debe evitar agregar o recuperar datos en esta tabla. Si se requiere hacer agregaciones y derivaciones, es mejor optar por hacer estas operaciones en una consulta, tablas de *data mart* o vistas. Y también es importante tener presente que las tablas de hechos no hacen referencia a otras tablas de hechos, solo hacen referencia a las dimensiones que se diagraman a su alrededor en el modelo estrella (Kimball y Ross, 2011). Se puede analizar el siguiente ejemplo de una tabla de hechos básica como la Tabla 9, partiendo de una pregunta que es común en negocios de venta de productos podría ser: "¿cuáles son las ventas brutas de pedidos de cada cliente por fecha?". Como se dijo antes, es importante que para poder dar respuesta a esta pregunta formulando la consulta, los datos deben estar al nivel más bajo o detallado posible; en este caso son los datos de: el identificador de los pedidos, el identificador del cliente, el identificador de fecha y el importe bruto de las ventas. Tenga en cuenta que los tipos de datos en la tabla de hechos son todos números (enteros y flotantes). (Reis y Housley, 2022)

También, el campo "NUMERO_ORDEN" tiene dos pedidos el mismo día, lo que refleja el nivel de granularidad o detalle de la tabla. Por su parte, la tabla de hechos tiene claves que hacen referencia a tablas de dimensiones que contienen los atributos relevantes referentes a la información de fechas y clientes. Y finalmente, las ventas brutas representan el volumen total de ventas de un evento de ventas.

Tabla 9. Ejemplo Tabla de hechos en Modelo Kimball

NUMERO ORDEN	ID CLIENTE	FECHA ID	IMPORTE VENTA
10	50	20240302	200
11	60	20240302	100
12	60	20240302	50
13	70	20240302	40
14	80	20240302	300

Fuente: modificado de Reis y Housley (2022)

- b. Tablas de dimensiones. el segundo tipo de tabla principal en el modelo de datos de Kimball se llama dimensión. Estas tablas tienen los datos de referencia, atributos y contexto relacional para todos los eventos almacenados en la tabla de hechos. Las tablas de dimensiones son más pequeñas que las tablas de hechos y tienen una forma opuesta, normalmente ancha y corta. Cuando se ejecutan las consultas que permiten unir la tabla de hechos con las dimensiones pueden describir qué, dónde y cuándo sucedió un hecho o evento dentro del negocio. Cabe aclarar que las dimensiones están desnormalizadas y por tanto hay posibilidad de duplicación de datos (Kimball y Ross, 2011). Retomando el ejemplo de la Tabla 9, en el modelo de datos de Kimball, las fechas generalmente se almacenan en una dimensión de fecha, lo que permite hacer referencia al campo Fecha entre una tabla de hechos y dimensiones de fecha. Con una tabla de dimensiones de fecha, puede responder fácilmente preguntas como: "¿cuáles son las ventas totales en el primer trimestre de 2024?" o "¿cuántos compradores compran más los lunes que los viernes?" Observando la tabla de la dimensión Fecha, además de la clave de fecha, se almacenan cinco campos, ver Tabla 9. En la dimensión de fecha es posible agregar los campos nuevos que tengan sentido para analizar los datos (Reis y Housley, 2022).

Tabla 10. Ejemplo Tabla de Dimensión Fecha en Modelo Kimball

FECHA_ID	FECHA_ISO	AÑO	SEMESTRE	MES	DÍA
20240302	2024-03-02	2024	1	3	Sábado
20240303	2024-03-03	2024	1	3	Domingo
20240304	2024-03-04	2024	1	3	Lunes
20240305	2024-03-05	2024	1	3	Martes
20240306	2024-03-06	2024	1	3	Miercoles

Fuente: modificado de Reis y Housley (2022)

La Tabla 11 es otro ejemplo de otra dimensión, la dimensión “Cliente” utilizando el campo ID_CLIENTE. Esta dimensión contiene varios campos que describen al cliente que son: nombre, apellido, dirección, ciudad y campos de fecha que son campos con un comportamiento peculiar.

Tabla 11. Ejemplo Tabla de Dimensión Cliente en Modelo Kimball

ID CLIENTE	NOMBRE	APELLIDO	DIRECCIÓN	CIUDAD	FECHA REGISTRO	FECHA ACTUALIZACION
50	Pepé	Sánchez	Cr 1 #12-3	San Luis	2020-02-04	2021-02-04
60	María	Gómez	Cll 3 #4-6	San Pelayo	2019-01-04	2022-01-04
60	José	Rodríguez	Trv 3 #8-50	Bacatá	2022-01-05	2021-01-05
70	Jesús	Pérez	Cr 23 #9-6	Chía	2021-01-02	2020-01-02
80	Sara	Ariza	Av 1 # 1 -4	San Benito	2022-04-04	2023-04-04

Fuente: modificado de Reis y Housley (2022)

Esta dimensión es un ejemplo de las dimensiones que cambian lentamente, en las que hay datos que permiten hacer seguimiento a los cambios dentro de la dimensión. En este caso está el campo “Fecha_Actualización”, el cual va sobrescribiendo la información en el registro de la información del cliente.

3. Proceso de extracción, transformación y carga de datos (ETL)

Los procesos de ETL incluyen: extracción, transformación y carga de datos, el proceso completo busca entregar los datos desde las fuentes de datos, sistemas fuente o fuentes transaccionales, para almacenarlos de forma unificada e integrada en bodegas de datos que permitan generar análisis de datos y alimentar modelos de minería de datos (Kimball y Ross, 2011; AWS, s. f.).

Al final, la importancia de este proceso es poder satisfacer necesidades específicas de la organización como predicción de resultados, dar soporte y fundamento a los procesos de toma de decisiones organizacionales, la generación de informes y cuadros de mando para reducir los que es ineficiente en la operación y proponer nuevos productos y servicios (AWS, s. f.).

3.1. Funcionamiento del proceso de ETL

El proceso ETL funciona en tres pasos:

1. Extracción de los datos relevantes de la base de datos de origen.
2. Transformación de los datos para que sean más adecuados para el análisis.
3. Carga de los datos en la base de datos de destino.

3.1.1. Extracción de los datos relevantes de la base de datos de origen

Esta fase busca la extracción o copia de los datos sin que sean procesados a partir de múltiples fuentes y se almacenan en un área de preparación de datos concreta. Esta zona de preparación es un área de almacenamiento temporal de los datos extraídos, y se eliminará una vez que se complete la extracción de datos. También se pueden almacenar archivos de datos que sirvan para posteriores procesos de resolución de problemas (Kimball y Ross, 2011).

La frecuencia con la que se hace este proceso de enviar los datos obtenidos desde las fuentes de datos dirigidos a la bodega de datos de destino va a depender de la estrategia de captura de datos y de la frecuencia con la cual el negocio genere datos nuevos. La minería de datos normalmente se realiza de una de las tres formas siguientes.

Procesamiento por alerta de actualización

A través de las alertas de actualización de datos, es posible notificar al sistema cuando cambia un registro. Lo que sigue después es la ejecución del proceso de extracción para los datos nuevos. En general, la mayoría de los motores de bases de datos y aplicaciones web proporcionan mecanismos de actualización para respaldar estos métodos de integración de los datos (AWS, s. f.)

Proceso por extracción progresiva

Si las fuentes de datos no generan las alertas de actualización de datos, se pueden identificar y extraer datos que han cambiado durante un período específico. En este caso, se programa el sistema para comprobar los cambios que se han producido en intervalos regulares, por ejemplo, con frecuencias de una vez a la semana, una vez al mes o al final de una campaña. Al final, solo se requiere la extracción de los datos que han cambiado (AWS, s. f.).

Proceso por extracción absoluta

En este escenario los sistemas no tienen la capacidad de detectar los cambios en los datos y tampoco recibir las alertas de actualización de datos, entonces la opción es que recargar todos los datos disponibles. Para que este método funcione, se requiere la conservación de una copia del conjunto extraído más reciente para que se pueda verificar cuáles son los nuevos registros. Es importante tener presente que este enfoque implica transferir grandes cantidades de datos, por tanto, la recomendación es usarlo solo para conjuntos de datos de tamaños reducidos (AWS, s. f.).

3.1.2. Transformación de los datos para que sean más adecuados para el análisis

En esta fase se hace una transformación y consolidación de los datos en estado bruto que se almacenaron previamente en el área de preparación con el fin de almacenarlos en el lugar de destino donde se tomarán para posteriores procesos de análisis y visualización de datos. La fase de transformación de datos puede implicar los siguientes tipos de cambios (AWS, s. f.).

Proceso de transformación básica de los datos

Este proceso incluye actividades para poder mejorar la calidad de los datos a través de la eliminación de errores, eliminación de campos de datos o también simplificar los conjuntos de datos. A continuación, se describen las transformaciones de datos que se hacen más frecuentemente (Kimball y Ross, 2011):

- **Limpieza de datos:** permite eliminar errores y completar datos, como, por ejemplo, puede asignar campos de datos vacíos al número 0, y cambiar una frase como “Cuenta de ahorro” a “CA” o asignar un número en vez de una frase o palabra como “Cuenta corriente” a “02”.
- **Quitar duplicación de datos:** se identifican y eliminan los registros que puedan estar duplicados en el conjunto de datos.
- **Revisión del formato de datos:** se revisan los formatos que son susceptibles de convertirse a otro formato como cadenas de caracteres, unidades de medida y valores de fecha/hora, en el formato que se requiera para el contexto, la herramienta o las necesidades de los análisis que se esperan ejecutar. Por ejemplo, una empresa que exporta productos puede tener diferentes bases de datos con precios en dólares y euros y en el sistema de ETL se decide convertir todo a euros.

Proceso de transformación avanzada de los datos

Estos procesos incluyen reglas de negocio que permiten optimizar los datos y facilitar el análisis. A continuación, se describen algunos ejemplos de estas transformaciones (AWS, s. f.).

- **Derivación:** aplica reglas comerciales a sus datos para calcular nuevos valores a partir de valores existentes. Se pueden convertir los ingresos en ganancias restando los gastos o calculando el costo total de una compra multiplicando el precio de cada artículo por la cantidad de artículos pedidos.
- **Vinculación:** en la fase de preparación de datos, la vinculación conecta los mismos datos de diferentes orígenes de datos. Por ejemplo, puede encontrar el costo total de compra de un artículo sumando el valor de compra de diferentes proveedores y almacenando solo el total final en el sistema de destino.
- **División:** se pueden dividir las columnas o atributos de datos en varias columnas en el sistema de destino. Por ejemplo, si el origen de datos guarda el nombre del cliente como “José Manuel Pérez”, puede dividirlo en nombre, segundo nombre y primer apellido.
- **Integración:** esta fase mejora la calidad de los datos al reducir una gran cantidad de valores de datos en un solo conjunto de datos. Por ejemplo, los valores de las facturas de los pedidos de los clientes pueden tener muchos importes pequeños diferentes. Puede integrar los datos sumándolos durante un período determinado para crear una métrica de valor de vida útil del cliente.
- **Cifrado:** en este proceso se busca la protección de los datos de acuerdo con su nivel de privacidad para cumplir con la legislación de datos o la privacidad que aplique de acuerdo con el contexto, organización o país donde se almacenan o procesan los datos agregando cifrado antes de que los datos se transmitan a la base de datos de destino.

3.1.3. Carga de los datos en la base de datos de destino

Para la mayoría de las organizaciones que utilizan ETL, el proceso necesita organizarse, darle estructura y automatizarlo con alguna herramienta, definiendo las fuentes de datos, y los posibles destinos. A continuación, se describen algunos métodos para cargar datos (Kimball y Ross, 2011):

Carga completa

Como su nombre lo indica es una carga completa de todos los datos desde la fuente, pasando por el lugar donde se van a transformar y luego su traslado al almacén de datos. Este tipo de carga se hace cuando carga datos por primera vez desde un sistema fuente en el almacén de datos (AWS, s. f.).

Carga de datos progresiva

Este tipo de carga de datos se configura en la herramienta ETL para que se carguen periódicamente los datos desde los sistemas de origen al de destino. Es importante almacenar la fecha de la última actualización para que solo se carguen los registros agregados después de esa fecha. Para que esto se pueda hacer hay dos formas de implementar la carga progresiva (AWS, s. f.):

- a. Transferencia de carga de datos progresiva: cuando se tienen disponibles conjuntos de datos de poco tamaño, es posible su transmisión de forma continua al almacén de datos de destino a través de canales dedicados solo para este fin. Si la evolución de esta situación indica que la velocidad de los datos aumenta a millones de eventos por segundo, es posible la utilización de procesamiento de flujos de eventos que permitan monitorear y procesar estos flujos de datos y ofrecer la oportunidad de tomar decisiones de forma más inmediata (AWS, s. f.).
- b. Carga de datos por lotes progresiva: si el caso de negocio incluye grandes cantidades de datos, se puede hacer captura de los datos usando lotes y los cambios de datos de carga a intervalos regulares. Bajo este esquema es necesario tener en cuenta que durante el período de tiempo que se destine para este proceso, no se pueden realizar acciones ni en el sistema de origen ni en el de destino mientras se sincronizan los datos (AWS, s. f.).

4. Preparación de datos para procesos de análisis y ciencia de datos

Esta fase es crítica para asegurar que los datos están listos y disponibles para los diferentes análisis y procesos de ciencia de datos. Si se hizo un proceso de ETL de forma adecuada, con las fuentes de datos idóneas y disponibles en la organización, y además se dejó una bodega de datos organizada y bien estructurada, los procesos de análisis se podrán ejecutar de una forma ágil y asegurando que sus resultados van a poder aportar elementos de valor en los procesos de toma de decisiones.

La descripción completa de este tema se encuentra en el segundo material fundamental de esta unidad.

5. Conclusiones

Según las necesidades de desarrollo de *software*, de análisis y ciencia de datos, se puede aprovechar diferentes formas de almacenar los datos para responder a las arquitecturas de *software* y arquitecturas de datos. Para implementar los modelos más adecuados para la organización, hay que identificar las fuentes de datos actuales, preguntar si se piensan cambiar en un futuro cercano e indagar sobre los requerimientos para analizar los datos, porque esto dará la información clave para la toma de decisiones en cuanto a los diseños y las herramientas necesarias para apoyar la operación y disponer de los datos para analizar, visualizar y publicar.

Lo que se observa con los proveedores de herramientas que se usan para todo el proceso de datos es que muchas de las que tienen trayectoria y tradición, tienden a ofrecer también servicios en nube que pueden ofrecer bastantes ventajas al negocio. Estas herramientas siguen evolucionando y para ofrecer mejores soluciones a las organizaciones es necesario estar actualizados con las herramientas que van publicando los proveedores que también van acompañadas de material de aprendizaje.

Referencias

AWS. (s. f.). ¿Qué es extracción, transformación y carga (ETL)? <https://aws.amazon.com/es/what-is/etl/#:~:text=El%20proceso%20ETL%20funciona%20en,base%20de%20datos%20de%20destino>

Inmon, H. (2005). *Building the Data Warehouse*. Wiley.

Kimball, R., & Ross, M. (2011). *The data warehouse toolkit: the complete guide to dimensional modeling*. John Wiley & Sons.

Kolade, C. (agosto de 2023). *Normalización de base de datos: formas normales 1nf 2nf 3nf ejemplos de tablas*. FreeCodeCamp. <https://www.freecodecamp.org/espanol/news/normalizacion-de-base-de-datos-formas-normales-1nf-2nf-3nf-ejemplos-de-tablas/>

Reis, J., & Housley, M. (2022). *Fundamentals of Data Engineering*. O'Reilly Media, Inc.

Torres, M. (2021). *Roles en la industria: cómo funcionan los equipos de datos e inteligencia artificial*. Platzi. <https://platzi.com/clases/2807-aprender-data-ia/46777-roles-en-la-industria-como-funcionan-los-equipos-d/>



Información técnica

Módulo: Arquitectura de Datos

Unidad 4: Procesamiento de datos orientados a diferentes modelos arquitectónicos

Autora: Isabel Andrea Mahecha Nieto

Asesora Pedagógica: Doris Amelia Gómez Torres

Diseñador Gráfico: Diego Andrés Calderón

Este material pertenece al Politécnico Grancolombiano.
Prohibida su reproducción total o parcial.